



ภาควิชาวิศวกรรมคอมพิวเตอร์ คณะวิศวกรรมศาสตร์

รหัสวิชา 04-624-201

มหาวิทยาลัยเทคโนโลยีราชมงคลธัญบุรี

ชื่อวิชา Machine Learning

ชื่อ นายสิทธิกร บุญณะ รหัสนักศึกษา 116630462039-4 กลุ่ม 1

ใบงานที่ 2 Neural Network

และการประยุกต์ใช้งาน NN

วัตถุประสงค์

1. เพื่อให้นักศึกษาเข้าใจหลักการทำงานของ Neural Network (NN) และแนวทางการประยุกต์ใช้ในงานจริงทั้งด้านการจำแนกและการพยากรณ์
2. เพื่อให้นักศึกษาสามารถพัฒนาผังการทำงาน ประมวลผล และแสดงผลลัพธ์ เพื่อพัฒนาระบบต้นแบบร่วมกับ NN ในการจำแนกและการพยากรณ์ได้อย่างถูกต้อง

LAB1: NN Basic for classify digits

Objective:

- Apply NN to classify digits.

Contents:

- Load the digits dataset.
- Split the data into training and testing sets.
- Train NN models.
- Evaluate each model using accuracy.

Output:

- Display sample predictions
- Compare the results of different network sizes in a table (1–10 layers with 10–1000 nodes per layer)

Code:

```
import numpy as np
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.datasets import load_digits
from sklearn.model_selection import
train_test_split
```

Flowchart:

```

from sklearn.neural_network import
MLPClassifier
from sklearn.metrics import accuracy_score
import warnings

warnings.filterwarnings('ignore')

def main():
    print("Loading digits dataset...")
    digits = load_digits()
    X = digits.data
    y = digits.target

    X_train, X_test, y_train, y_test =
train_test_split(X, y, test_size=0.2,
random_state=42)

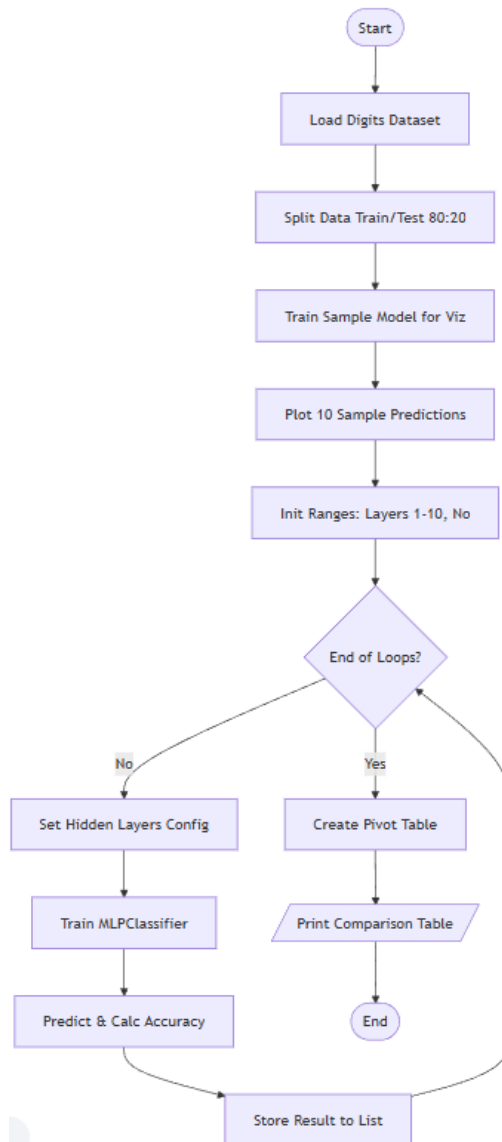
    print(f"Data split: {X_train.shape[0]} training
samples, {X_test.shape[0]} testing samples.")

    print("\nTraining a sample model for
visualization...")
    sample_mlp =
MLPClassifier(hidden_layer_sizes=(100),
max_iter=500, random_state=42)
    sample_mlp.fit(X_train, y_train)

    y_pred_sample =
sample_mlp.predict(X_test)
    sample_accuracy = accuracy_score(y_test,
y_pred_sample)
    print(f"Sample Model Accuracy:
{sample_accuracy:.4f}")

    print("Displaying sample predictions...")
    fig, axes = plt.subplots(2, 5, figsize=(10, 5))

```



```

for i, ax in enumerate(axes.flat):
    ax.imshow(X_test[i].reshape(8, 8),
cmap='binary')
    ax.set_title(f"True: {y_test[i]}\nPred:
{y_pred_sample[i]}")
    ax.axis('off')
plt.tight_layout()
plt.show()

print("\nComparing different network sizes
(this may take a while)...")

layers_range = range(1, 11)
nodes_range = [10, 50, 100, 500, 1000]

results = []

for layers in layers_range:
    for nodes in nodes_range:
        hidden_layers = tuple([nodes] * layers)

        mlp =
MLPClassifier(hidden_layer_sizes=hidden_layers,
max_iter=200, random_state=42)
        mlp.fit(X_train, y_train)

        y_pred = mlp.predict(X_test)
        acc = accuracy_score(y_test, y_pred)

        print(f"Layers: {layers}, Nodes/Layer:
{nodes} -> Accuracy: {acc:.4f}")

        results.append({
            'Hidden Layers': layers,
            'Nodes per Layer': nodes,
            'Accuracy': acc

```

```
    })

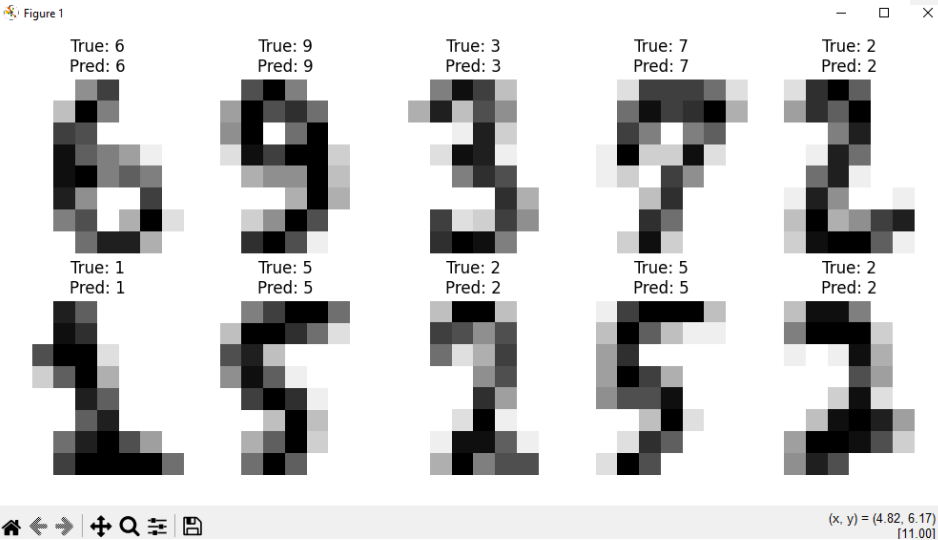
    results_df = pd.DataFrame(results)

    pivot_table = results_df.pivot(index='Hidden
Layers', columns='Nodes per Layer',
values='Accuracy')

    print("\nComparison Results (Accuracy):")
    print(pivot_table)

if __name__ == "__main__":
    main()
```

Result:



ให้ข้อคิดเห็น [สว1]: AI
จำแนกตัวเลขเขียนด้วยมือ (Handwritten Digits
Classification) โดยใช้ Neural Network (MLP) มีขั้นตอน
หลักดังนี้:

1.เตรียมข้อมูล (Data Preparation):

(1)

- ใช้ชุดข้อมูล **Digits** (รูปภาพ 8x8 พิกเซล ของตัวเลข 0-9)
- แบ่งข้อมูลเป็น **Train 80%** และ **Test 20%**

1.ตรวจสอบเบื้องต้น (Visualization):

(1)

(1)สร้างโมเดลตัวอย่างเพื่อทดสอบและแสดงผลเป็นรูปภาพ 10
รูป

(2)เปรียบเทียบค่าจริง (**True**) กับค่าที่ทำนาย (**Pred**) เพื่อ
ขึ้นชั้นว่าโมเดลทำงานถูกต้อง

1.การทดลองเปรียบเทียบโครงสร้าง (Experiment):

(1)

(1)ทำการทดลองซ้ำๆ (Loop) โดยปรับเปลี่ยนขนาดของ
Network 2 ตัวแปร:

(2)

- จำนวนชั้น (**Hidden Layers**): ตั้งแต่ 1 ถึง 10 ชั้น
- จำนวนโหนด (**Nodes**): 10, 50, 100, 500, และ 1000
โหนด

LEB 2: NN on the Face recognition.

Objective:

- Apply NN to Face recognition.

Contents:

- Load face recognition library.
- Split the data into training and testing sets.
- Train NN models.
- Evaluate each model using accuracy.

Output:

- Display sample predictions
- Compare the results of different network sizes in a table (1–10 layers with 10–1000 nodes per layer)

Code:

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.datasets import fetch_lfw_people
from sklearn.model_selection import
train_test_split
from sklearn.neural_network import MLPClassifier
from sklearn.metrics import accuracy_score
import warnings
```

```
warnings.filterwarnings('ignore')
```

def main():

```
    print("Loading Face Dataset (LFW)...")
    lfw_people =
fetch_lfw_people(min_faces_per_person=70,
resize=0.4)

    n_samples, h, w = lfw_people.images.shape
    X = lfw_people.data
    y = lfw_people.target
    target_names = lfw_people.target_names
```

Flowchart:

ให้ข้อคิดเห็น [ลบ2]: AI
ปิด Warning เพื่อความสะอาดของ Output

```

n_classes = target_names.shape[0]

print(f"Dataset Info: {n_samples} samples,
{n_classes} classes, Image size: {h}x{w}")

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.25, random_state=42
)

print("\nComparing different network sizes...")

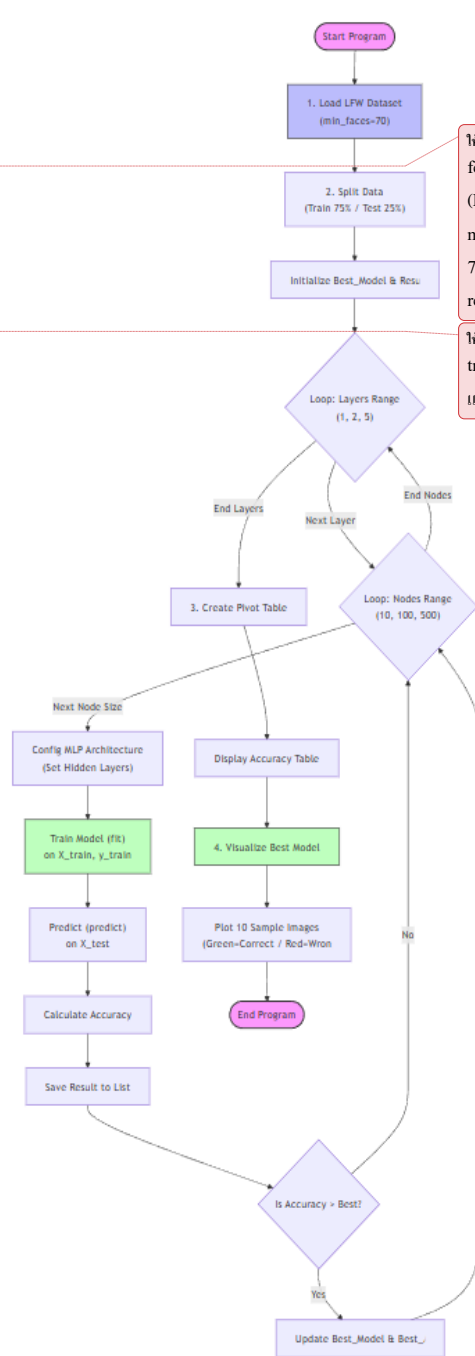
layers_range = [1, 2, 5]
nodes_range = [10, 100, 500]

results = []

best_model = None
best_acc = 0

for layers in layers_range:
    for nodes in nodes_range:
        hidden_layers = tuple([nodes] * layers)
        print(f" -> Training: {layers} Layers x
{nodes} Nodes...")
        mlp =
MLPClassifier(hidden_layer_sizes=hidden_layers,
max_iter=200, random_state=42)
        mlp.fit(X_train, y_train)
        y_pred = mlp.predict(X_test)
        acc = accuracy_score(y_test, y_pred)
        results.append({
            'Layers': layers,
            'Nodes/Layer': nodes,
            'Accuracy': acc
        })
        if acc > best_acc:

```



ให้ข้อคิดเห็น [ตบ3]: AI
fetch_lfw_people: คำสั่งนี้จะไปโหลดรูปภาพใบหน้าคนดัง (LFW Dataset) มาจาก Server ของ Scikit-learn
min_faces_per_person=70: เลือกโหลดเฉพาะคนที่มียุโรปมากกว่า 70 รูป เพื่อให้โมเดลมีตัวอย่างสอนเยอะพอจนจำแนกได้
resize=0.4: ย่อรูปให้เล็กลง เพื่อให้เทรนไวขึ้น

ให้ข้อคิดเห็น [ตบ4]: AI
train_test_split: แบ่งข้อมูลเป็น 2 กอง คือ Train (สำหรับสอน) และ Test (สำหรับสอบ) สัดส่วน 75:25 (เพราะ test_size=0.25)

```

        best_acc = acc
        best_model = mlp
    results_df = pd.DataFrame(results)
    pivot_table = results_df.pivot(index='Layers',
columns='Nodes/Layer', values='Accuracy')
    print("\n" + "="*40)
    print(" Comparison Results (Accuracy) ")
    print("="*40)
    print(pivot_table)
    print("="*40)
    if best_model is not None:
        print("\nDisplaying sample predictions form
Best Model...")
        y_pred_best = best_model.predict(X_test)
        plt.figure(figsize=(12, 5))
        for i in range(10):
            plt.subplot(2, 5, i + 1)
            plt.imshow(X_test[i].reshape(h, w),
cmap='gray')
            true_name =
target_names[y_test[i]].split()[-1]
            pred_name =
target_names[y_pred_best[i]].split()[-1]
            color = 'green' if y_pred_best[i] ==
y_test[i] else 'red'
            plt.title(f"T:{true_name}\nP:{pred_name}",
color=color, fontsize=10)
            plt.axis('off')
            plt.suptitle(f"Face Recognition Results (Best
Acc: {best_acc:.4f})")
            plt.tight_layout()
            plt.show()
        else:
            print("No model trained.")
    if __name__ == "__main__":
        main()

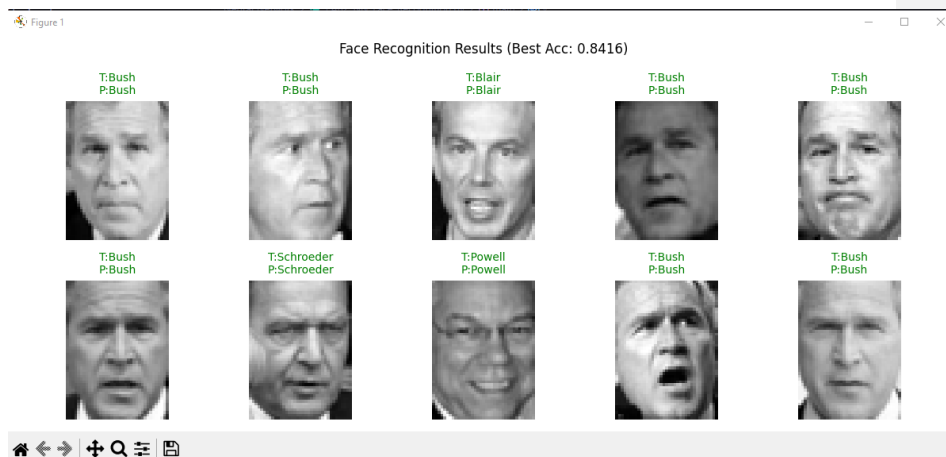
```

ให้ชื่อคิดเห็น **[สว5]:** AI Compare Network Sizes (ตามโจทย์ 1-10 Layers, 10-1000 Nodes)
กำหนดช่วงที่จะทดสอบ (ลดจำนวนลงเล็กน้อยเพื่อให้รันเสร็จไวขึ้นสำหรับการทดสอบ)
Loop Compare Network Sizes: ส่วนนี้คือหัวใจสำคัญ
layers_range: เก็บจำนวนชั้น Hidden Layer ที่จะทดสอบ (เช่น 1, 2, 5 ชั้น)
nodes_range: เก็บจำนวน Node ต่อชั้น (เช่น 10, 100, 500 Nodes)
โปรแกรมจะวนลูปจับคู่ "ชั้น x โหนด" ทุกแบบ แล้วสร้าง MLPClassifier มาเทรน

ให้ชื่อคิดเห็น **[สว6]:** Display Results Table

ให้ชื่อคิดเห็น **[สว7]:** AI คอนจบจะเอาผล Accuracy ทั้งหมดมาตีตารางให้ดูง่ายๆ ว่าโครงสร้างแบบไหนฉลาดที่สุด
Visualization: เอารูปภาพจาก Test set 10 รูปมาใส่ best_model ทำนาย
ถ้าชื่อสี เขียว แปลว่าทายถูก
ถ้าชื่อสี แดง แปลว่าทายผิด

Result:



Loading Face Dataset (LFW)... (อาจใช้เวลาดาวน์โหลดสักครู่ในครั้งแรก)
Dataset Info: 1288 samples, 7 classes, Image size: 50x37

Comparing different network sizes... (Process might take time)

- > Training: 1 Layers x 10 Nodes...
- > Training: 1 Layers x 100 Nodes...
- > Training: 1 Layers x 500 Nodes...
- > Training: 2 Layers x 10 Nodes...
- > Training: 2 Layers x 100 Nodes...
- > Training: 2 Layers x 500 Nodes...
- > Training: 5 Layers x 10 Nodes...
- > Training: 5 Layers x 100 Nodes...
- > Training: 5 Layers x 500 Nodes...

=====
Comparison Results (Accuracy)

Nodes/Layer	10	100	500
Layers			
1	0.736025	0.841615	0.841615
2	0.655280	0.841615	0.804348
5	0.652174	0.782609	0.742236

=====
Displaying sample predictions form Best Model...

LEB 3: NN on Iris.csv. Classification.

Link: <https://www.kaggle.com/datasets/saurabh00007/iriscsv>

Objective:

- Apply NN to Iris.csv.

Contents:

- Load the iris.csv data from directory dataset.
- Split the data into training and testing sets.
- Train NN models using 5 layers (1 layer: 50 Node)
- Evaluate each model using accuracy.

Output:

- Display sample predictions.
- Compare the results of different learning rates in a table (10^{-2} , to 10^{-5})

Code:

```
import pandas as pd
import numpy as np
from sklearn.model_selection import
train_test_split
from sklearn.preprocessing import LabelEncoder,
StandardScaler
from sklearn.neural_network import MLPClassifier
from sklearn.metrics import accuracy_score
import warnings
import os
warnings.filterwarnings('ignore')
def main():
    print("Loading Iris dataset...")
    possible_paths = ['dataset/Iris.csv',
'../dataset/Iris.csv']
    dataset_path = None
    for path in possible_paths:
        if os.path.exists(path):
            dataset_path = path
            break
    if dataset_path is None:
```

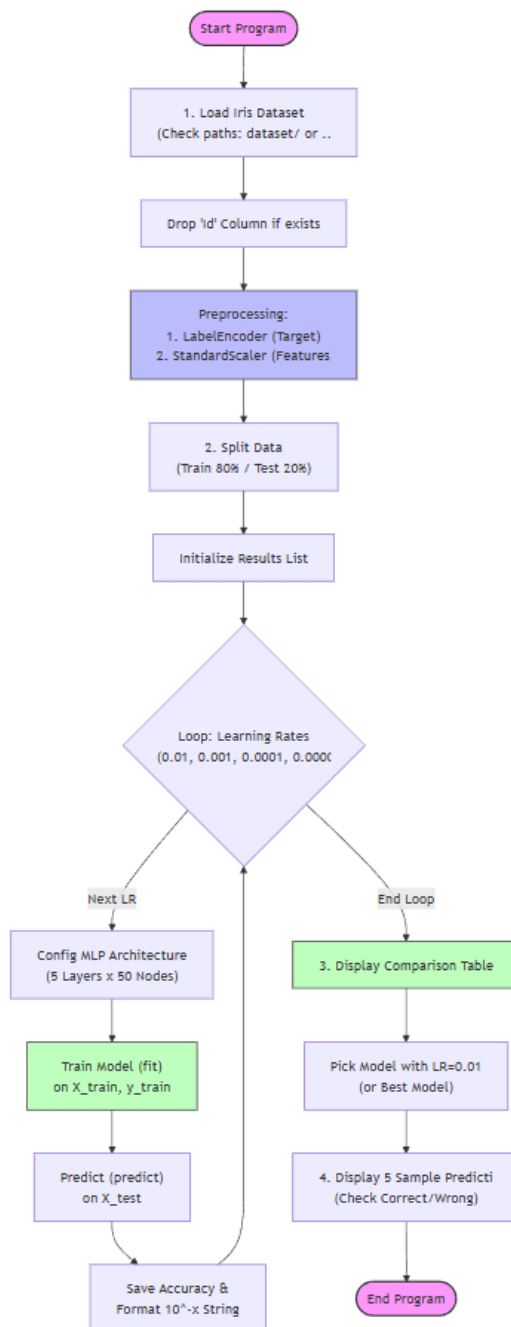
Flowchart:

```

print("Error: ไม่พบไฟล์ 'dataset/Iris.csv'")
print("กรุณาสร้างโฟลเดอร์ 'dataset' และใส่ไฟล์ Iris.csv ลงไป หรือแก้ไข path ในโค้ด")

return
df = pd.read_csv(dataset_path)
if 'Id' in df.columns:
    df = df.drop('Id', axis=1)
X = df.iloc[:, :-1]
y = df.iloc[:, -1]
le = LabelEncoder()
y = le.fit_transform(y)
scaler = StandardScaler()
X = scaler.fit_transform(X)
X_train, X_test, y_train, y_test =
train_test_split(
    X, y, test_size=0.2, random_state=42
)
learning_rates = [0.01, 0.001, 0.0001, 0.00001]
hidden_layers_config = (50, 50, 50, 50, 50)
results = []
models = {}
print(f"\nTraining NN with 5 Layers
{hidden_layers_config}...")
print(f'{"Learning Rate":<15} | {"Accuracy":<10}')
print("-" * 30)
for lr in learning_rates:
    mlp = MLPClassifier(
        hidden_layer_sizes=hidden_layers_config,
        learning_rate_init=lr,
        max_iter=1000,
        random_state=42
    )
    mlp.fit(X_train, y_train)
    y_pred = mlp.predict(X_test)
    acc = accuracy_score(y_test, y_pred)

```



```



results.append({
    'Learning Rate': lr,
    'LR Scientific': f"10^{int(np.log10(lr))}",
    'Accuracy': acc
})
models[lr] = mlp
print(f"{lr:<15} | {acc:.4f}")
results_df = pd.DataFrame(results)
results_df = results_df[['LR Scientific', 'Learning
Rate', 'Accuracy']]

print("\n" + "="*40)
print(" Comparison Results (Learning Rate) ")
print("="*40)
print(results_df)
print("="*40)
best_lr = 0.01
best_model = models[best_lr]
print(f"\nSample Predictions (using model with
LR={best_lr}):")
sample_indices =
np.random.choice(len(X_test), 5, replace=False)

X_sample = X_test[sample_indices]
y_sample_true = y_test[sample_indices]

y_sample_pred = best_model.predict(X_sample)
y_true_names =
le.inverse_transform(y_sample_true)

y_pred_names =
le.inverse_transform(y_sample_pred)

for i in range(5):
    status = "  Correct" if y_sample_true[i]
== y_sample_pred[i] else "  Wrong"

```

```
print(f"Sample {i+1}:  
True=[{y_true_names[i]:<15}] vs  
Pred=[{y_pred_names[i]:<15}] -> {status}")  
if __name__ == "__main__":  
    main()
```

Result:

```
Loading Iris dataset...  
  
Training NN with 5 Layers (50, 50, 50, 50, 50)...  
Learning Rate | Accuracy  
-----  
0.01          | 0.9667  
0.001         | 1.0000  
0.0001        | 1.0000  
1e-05         | 0.7000  
  
=====
```

Comparison Results (Learning Rate)			
LR Scientific	Learning Rate	Accuracy	
0	10 ⁻²	0.01000	0.966667
1	10 ⁻³	0.00100	1.000000
2	10 ⁻⁴	0.00010	1.000000
3	10 ⁻⁵	0.00001	0.700000

```
=====
```

Sample Predictions (using model with LR=0.01):

Sample 1:	True=[Iris-setosa]	vs Pred=[Iris-setosa]	-> ✔ Correct
Sample 2:	True=[Iris-setosa]	vs Pred=[Iris-setosa]	-> ✔ Correct
Sample 3:	True=[Iris-setosa]	vs Pred=[Iris-setosa]	-> ✔ Correct
Sample 4:	True=[Iris-virginica]	vs Pred=[Iris-virginica]	-> ✔ Correct
Sample 5:	True=[Iris-setosa]	vs Pred=[Iris-setosa]	-> ✔ Correct

ให้ข้อคิดเห็น [ลบ8]: AI

ส่วนที่ 1: การนำเข้าเครื่องมือ (Import Libraries)

ส่วนบนสุดของโค้ดคือการเรียกใช้ Library ที่จำเป็นสำหรับงาน Data Science และ Machine Learning:

- **pandas**: ใช้จัดการข้อมูลในรูปแบบตาราง (DataFrame) และอ่านไฟล์ CSV
- **numpy**: ใช้สำหรับการคำนวณทางคณิตศาสตร์และจัดการ Array
- **sklearn (Scikit-learn)**: เป็นพระเอกหลักที่ใช้สำหรับ:
 - แบ่งข้อมูล (train_test_split)
 - เติร์มข้อมูล (LabelEncoder, StandardScaler)
 - สร้างโมเดล Neural Network (MLPClassifier)
 - วัดผล (accuracy_score)

ส่วนที่ 2: การโหลดไฟล์ข้อมูล (Load Data with Path Check)

โค้ดส่วนนี้ออกแบบมาให้ **Robust (แข็งแกร่ง)** ป้องกัน Error เรื่องหาไฟล์ไม่เจอ:

1. **possible_paths**: กำหนดรายชื่อที่อยู่ไฟล์ที่เป็นไปได้ (เช่น dataset/Iris.csv หรือ ../dataset/Iris.csv)
2. **for path in possible_paths**: วนดูเช็คว่ามีไฟล์อยู่ที่ไหน ถ้าเจอ (os.path.exists) ให้จำ Path นั้นไว้แล้วหยุดหา
3. **Error Handling**: ถ้าหาไม่เจอเลย จะแจ้งเตือนให้ผู้ใช้สร้างไฟล์หรือแก้ Path ก่อนจบโปรแกรม

ส่วนที่ 3: การเตรียมข้อมูล (Preprocessing)

เมื่อโหลดข้อมูลมาแล้ว ต้องทำความสะอาดและแปลงร่างก่อนส่งให้ AI เรียนรู้:

1. **Drop ID**: ลบคอลัมน์ Idทิ้ง เพราะเป็นแค่เลขรหัส ไม่ช่วยในการแยกแยะสายพันธุ์ออกไม๊
2. **แยก X, y**:
 - (1) **X (Features)**: ข้อมูลนำเข้า (ความกว้าง/ยาวของกลีบ)
 - y (Target)**: ค่าตอบที่ต้องการทำนาย (ชื่อสายพันธุ์)
1. **Label Encoding**: แปลงชื่อสายพันธุ์ที่เป็นตัวหนังสือ (เช่น "Iris-setosa") ให้เป็นตัวเลข (0, 1, 2) เพื่อให้คอมพิวเตอร์เข้าใจ
2. **Standard Scaler**: สำคัญมากสำหรับ Neural Network คือการปรับค่าข้อมูลทุกคอลัมน์ให้อยู่ในสเกลเดียวกัน (Mean=0, Std=1) เพื่อให้โมเดลเรียนรู้ได้เร็วและแม่นยำ

ส่วนที่ 4: การแบ่งข้อมูล (Train/Test Split)

Python
X_train, X_test, y_train, y_test = train_test_split(...)

แบ่งข้อมูลออกเป็น 2 กอง:

- **Train (80%)**: เอาไว้สอนโมเดล (ให้เรียนรู้)
- **Test (20%)**: เอาไว้สอบวัดผล (ห้ามแอบดูเฉลย)
- **random_state=42**: ล็อกผลการสุ่มให้เหมือนเดิมทุกครั้งที่รัน (เพื่อให้ผลการทดลองนิ่ง)

ส่วนที่ 5: การทดลองและเทรนโมเดล (Experiment Loop)

LEB 4: NN on Microscopic Fungi Classification

Link: <https://www.kaggle.com/datasets/anshtanwar/microscopic-fungi-images>

Objective:

- Apply NN to Fungi classify.

Contents:

- Load the Fungi dataset from directory (Link).
- Split the data into training and testing sets.
- Train NN models using 5 layers (1 layer: 100 Node)
- Evaluate each model using accuracy.

Output:

- Classification accuracy on the test set.
- Compare the results of different network sizes in a table (1–10 layers with 10–1000 nodes per layer)
- Compare the results of different learning rates in a table (10^{-2} , to 10^{-5})

Code or Algorithms:

```
import os
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.neural_network import MLPClassifier
from sklearn.metrics import accuracy_score
from sklearn.preprocessing import LabelEncoder
from PIL import Image
import warnings
warnings.filterwarnings('ignore')

def load_images_from_folder(folder, image_size=(32, 32)):
    images = []
    labels = []

    if not os.path.exists(folder):
        print(f"Error: Folder not found: {folder}")
```

Flowchart:

ให้ข้อคิดเห็น [ลบ9]: ปิด Warning เพื่อความสะอาดของ Output

```

    return np.array(images), np.array(labels)

print(f"Scanning folder: {folder}")

# วนลูปตามโฟลเดอร์ของแต่ละคลาส (class_name)
for filename in os.listdir(folder):
    class_path = os.path.join(folder, filename)

    # ถ้าเป็นโฟลเดอร์ (คือ Class)
    if os.path.isdir(class_path):
        class_name = filename
        # อ่านรูปภาพใน Class นั้นๆ
        for img_name in os.listdir(class_path):
            img_path = os.path.join(class_path,
img_name)
            try:
                with Image.open(img_path) as img:
                    # Resize รูปให้เล็กลงเพื่อลดจำนวน
Features (เช่น 32x32 = 1024 pixels)
                    img =
img.resize(image_size).convert('RGB')
                    # แปลงเป็น numpy array และ Normalize
(0-1)
                    img_array = np.array(img).flatten() /
255.0

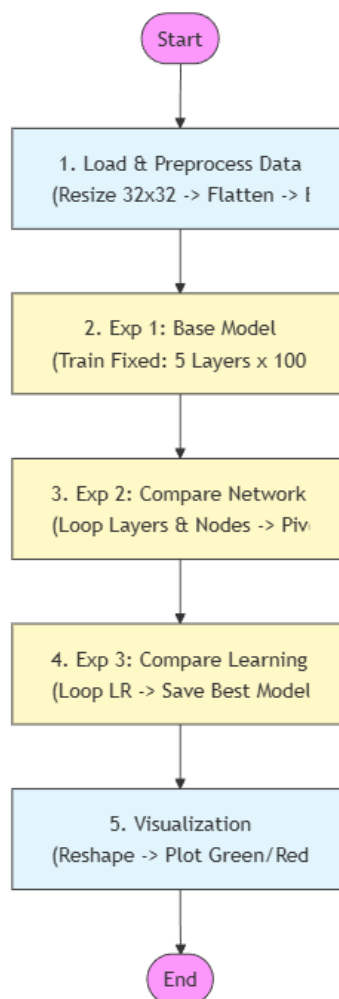
                    images.append(img_array)
                    labels.append(class_name)
            except Exception as e:
                pass

    # กรณี dataset ไม่มี subfolder (รูปกองรวมกัน) - ข้ามไป
ก่อน หรือเขียน logic เพิ่ม

return np.array(images), np.array(labels)

def main():

```



```

print("="*50)
print(" LAB 4: NN on Microscopic Fungi Classification")
print("="*50)

# -----
# 1. Load Dataset
# -----

train_dir = "../dataset/fungi/train"
test_dir = "../dataset/fungi/test"

# Fallback paths
if not os.path.exists(train_dir): train_dir =
"dataset/fungi/train"
if not os.path.exists(test_dir): test_dir =
"dataset/fungi/test"

print("\nLoading Training Data...")
X_train, y_train_labels =
load_images_from_folder(train_dir, image_size=(32, 32))

print("\nLoading Testing Data...")
X_test, y_test_labels =
load_images_from_folder(test_dir, image_size=(32, 32))

if len(X_train) == 0:
    print("Error: No training data found. Please check
dataset path.")
    return

print(f"\nData Loaded:")
print(f"Train: {X_train.shape} samples")
print(f"Test: {X_test.shape} samples")

# Encode Labels
le = LabelEncoder()
y_train = le.fit_transform(y_train_labels)

```

```

y_test = le.transform(y_test_labels)

classes = le.classes_
print(f"Classes: {classes}")

# -----
# 2. Experiment 1: 5 Layers (100 Nodes each)
# -----

print("\n" + "-"*50)
print(" Experiment 1: 5 Layers x 100 Nodes")
print("-" * 50)

mlp_base = MLPClassifier(hidden_layer_sizes=(100,
100, 100, 100, 100), max_iter=200, random_state=42)
mlp_base.fit(X_train, y_train)

acc_base = mlp_base.score(X_test, y_test)
print(f"Base Model Accuracy: {acc_base:.4f}")

# -----
# 3. Experiment 2: Compare Network Sizes
# -----

print("\n" + "-"*50)
print(" Experiment 2: Compare Network Sizes (Layers &
Nodes)")
print("-" * 50)

layers_test = [1, 3, 5]
nodes_test = [10, 50, 100]

results_size = []

for l in layers_test:
    for n in nodes_test:
        hidden_layers = tuple([n] * l)
        print(f"Training: {{l}} Layers, {{n}} Nodes...")

```

```

        mlp =
MLPClassifier(hidden_layer_sizes=hidden_layers,
max_iter=100, random_state=42)
        mlp.fit(X_train, y_train)
        acc = mlp.score(X_test, y_test)

        results_size.append({'Layers': l, 'Nodes': n,
'Accuracy': acc})

df_size = pd.DataFrame(results_size)
pivot_size = df_size.pivot(index='Layers',
columns='Nodes', values='Accuracy')
print("\nNetwork Size Comparison (Accuracy):")
print(pivot_size)

# -----
# 4. Experiment 3: Compare Learning Rates
# -----
print("\n" + "-"*50)
print(" Experiment 3: Compare Learning Rates (10^-2
to 10^-5)")
print("-" * 50)

learning_rates = [0.01, 0.001, 0.0001, 0.00001]
results_lr = []

best_model = None
best_acc = 0

# ใช้โครงสร้างเดิม (5 Layers, 100 Nodes) เพื่อทดสอบ LR
fixed_structure = (100, 100, 100, 100, 100)

for lr in learning_rates:
    print(f"Training LR: {lr}...")

```

```

mlp =
MLPClassifier(hidden_layer_sizes=fixed_structure,
learning_rate_init=lr, max_iter=200, random_state=42)
mlp.fit(X_train, y_train)
acc = mlp.score(X_test, y_test)

results_lr.append({
    'Learning Rate': lr,
    'LR Scientific': f"10^{int(np.log10(lr))}",
    'Accuracy': acc
})

if acc >= best_acc:
    best_acc = acc
    best_model = mlp

df_lr = pd.DataFrame(results_lr[['LR Scientific',
'Learning Rate', 'Accuracy']])
print("\nLearning Rate Comparison:")
print(df_lr)

# -----
# 5. Sample Predictions
# -----
print("\n" + "-"*50)
print(" Sample Predictions (Best Model)")
print("-" * 50)

# สุ่มรูปมาแสดง 10 รูป
indices = np.random.choice(len(X_test), 10,
replace=False)

plt.figure(figsize=(15, 6))
for i, idx in enumerate(indices):
    image = X_test[idx].reshape(32, 32, 3) # Reshape
    กลับเป็นรูปภาพ (32x32x3)

```

```

true_label = le.inverse_transform([y_test[idx]])[0]
pred_label =
le.inverse_transform([best_model.predict([X_test[idx]])])[0]

color = 'green' if true_label == pred_label else 'red'

plt.subplot(2, 5, i+1)
plt.imshow(image)
plt.title(f"True: {true_label}\nPred: {pred_label}",
color=color)
plt.axis('off')

plt.tight_layout()
plt.show()

if __name__ == "__main__":
    main()

```

ให้ข้อคิดเห็น [ลบ10]: AI

ช่วงโค้ด: ตั้งแต่ import ... จนจบฟังก์ชัน

load_images_from_folder

•สิ่งที่ทำ:

- นำเข้า Library ที่จำเป็น (NumPy, Pandas, Sklearn, PIL, Matplotlib)
- สร้างฟังก์ชัน load_images_from_folder: เปรียบเสมือน "คนงาน" ที่เดินเข้าไปในโฟลเดอร์
- **Resize:** ขยายรูปเหลือ 32x32 pixel (เพื่อลดภาระการคำนวณ)
- **Flatten:** แปลงรูปภาพที่เป็นแผ่นสี่เหลี่ยม ให้กลายเป็น "เส้นตรงยาวๆ" (Vector) เพราะ MLPClassifier รับข้อมูลแบบเส้นตรงเท่านั้น
- **Normalize:** หาค่า 255.0 เพื่อปรับค่าสีจาก 0-255 ให้เหลือช่วง 0-1 (ช่วยให้ AI เรียนรู้ไวขึ้น)

2. ส่วนโหลดข้อมูลและแปลง

ช่วงโค้ด: เริ่มต้น def main(): ... ถึง print(f"Classes: {classes}")

•สิ่งที่ทำ:

- กำหนด Path ของโฟลเดอร์รูปภาพ (มีระบบกัน Error ถ้าหาไฟล์ไม่เจอ)
 - เรียกใช้ฟังก์ชันจากข้อ 1 มาโหลดข้อมูลได้ตัวแปร X_train (รูปภาพ) และ y_train_labels (ชื่อคลาส)
 - **Label Encoder:** แปลงชื่อชื่อ (เช่น "H1", "H2") ให้เป็นตัวเลข (0, 1) เพื่อให้คอมพิวเตอร์นำไปคำนวณต่อได้
- ผมจะแบ่งคำอธิบายโดยจับคู่กับ "ช่วงบรรทัดของโค้ด" ให้เห็นภาพชัดเจนนะครับ คุณสามารถนำหัวข้อเหล่านี้ไปเขียนลงในรายงานหรือสไลด์นำเสนอได้เลยครับ

1. ส่วนเตรียมการและฟังก์ชันจัดการรูปภาพ (บรรทัดที่ 1 - 42)

ช่วงโค้ด: ตั้งแต่ import ... จนจบฟังก์ชัน

load_images_from_folder

•สิ่งที่ทำ:

- นำเข้า Library ที่จำเป็น (NumPy, Pandas, Sklearn, PIL, Matplotlib)
- สร้างฟังก์ชัน load_images_from_folder: เปรียบเสมือน "คนงาน" ที่เดินเข้าไปในโฟลเดอร์
- **Resize:** ขยายรูปเหลือ 32x32 pixel (เพื่อลดภาระการคำนวณ)
- **Flatten:** แปลงรูปภาพที่เป็นแผ่นสี่เหลี่ยม ให้กลายเป็น "เส้นตรงยาวๆ" (Vector) เพราะ MLPClassifier รับข้อมูลแบบเส้นตรงเท่านั้น
- **Normalize:** หาค่า 255.0 เพื่อปรับค่าสีจาก 0-255 ให้เหลือช่วง 0-1 (ช่วยให้ AI เรียนรู้ไวขึ้น)

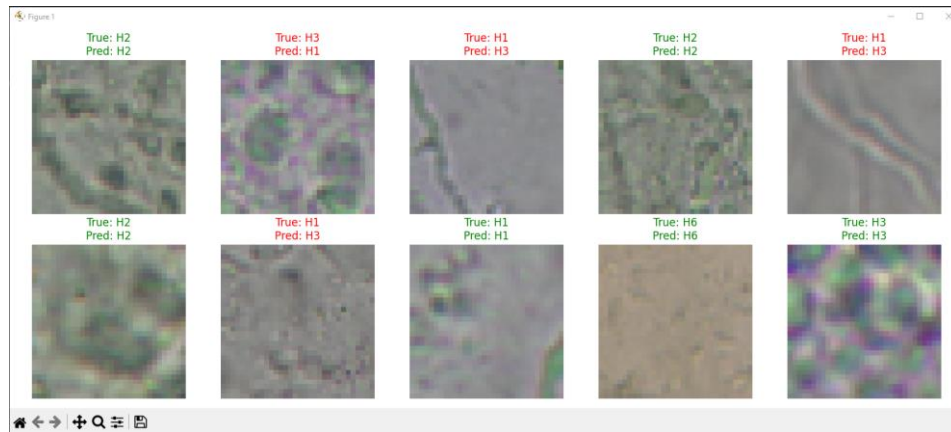
2. ส่วนโหลดข้อมูลและแปลงผล (บรรทัดที่ 44 - 83)

ช่วงโค้ด: เริ่มต้น def main(): ... ถึง print(f"Classes: {classes}")

•สิ่งที่ทำ:

-

Result:



```

Training: 1 Layers, 10 Nodes...
-----
Training: 1 Layers, 10 Nodes...
Training: 1 Layers, 10 Nodes...
Training: 1 Layers, 50 Nodes...
Training: 1 Layers, 50 Nodes...
Training: 1 Layers, 100 Nodes...
Training: 3 Layers, 10 Nodes...
Training: 1 Layers, 100 Nodes...
Training: 3 Layers, 10 Nodes...
Training: 3 Layers, 50 Nodes...
Training: 3 Layers, 10 Nodes...
Training: 3 Layers, 50 Nodes...
Training: 3 Layers, 50 Nodes...
Training: 3 Layers, 100 Nodes...
Training: 3 Layers, 100 Nodes...
Training: 5 Layers, 10 Nodes...
Training: 5 Layers, 10 Nodes...
Training: 5 Layers, 50 Nodes...
Training: 5 Layers, 100 Nodes...

Network Size Comparison (Accuracy):
Nodes      10      50      100
Layers
1          0.526608 0.550998 0.424612
3          0.576497 0.494457 0.573171
5          0.497783 0.533259 0.552106

-----
Experiment 3: Compare Learning Rates (10^-2 to 10^-5)
-----
Training LR: 0.01...
Training LR: 0.001...
Training LR: 0.0001...
Training LR: 1e-05...

Learning Rate Comparison:
LR Scientific Learning Rate Accuracy
0          10^-2      0.01000 0.431264
1          10^-3      0.00100 0.566519
2          10^-4      0.00010 0.525499
3          10^-5      0.00001 0.552106

-----
Sample Predictions (Best Model)
-----

```

LEB 5: NN for Blood Cells

Link: <https://www.kaggle.com/datasets/unclesamulus/blood-cells-image-dataset>

Objective:

- Apply NN to Blood Cells classify.

Contents:

- Load the Blood Cells dataset from directory (Link).
- Split the data into training and testing sets.
- Train NN models
- Evaluate each model using accuracy

Output:

- Classification accuracy on the test set.
- Compare the results of different network sizes in a table (1–10 layers with 10–1000 nodes per layer)
- Compare the results of different learning rates in a table (10^{-2} , to 10^{-5})

Code or Algorithms:

```
import os
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.neural_network import MLPClassifier
from sklearn.metrics import accuracy_score
from sklearn.preprocessing import LabelEncoder
from sklearn.model_selection import train_test_split
from PIL import Image
import warnings

warnings.filterwarnings('ignore')

def load_data(root_folder, image_size=(64, 64),
max_samples_per_class=None):
    images = []
    labels = []

    if not os.path.exists(root_folder):
        print(f"Error: Folder not found: {root_folder}")
```

Flowchart:

```

    return np.array(images), np.array(labels)

print(f"Scanning folder: {root_folder}")

classes = [d for d in os.listdir(root_folder) if
os.path.isdir(os.path.join(root_folder, d))]
print(f"Found {len(classes)} Classes: {classes}")

for class_name in classes:
    class_path = os.path.join(root_folder, class_name)
    count = 0
    for img_name in os.listdir(class_path):
        if max_samples_per_class and count >=
max_samples_per_class:
            break

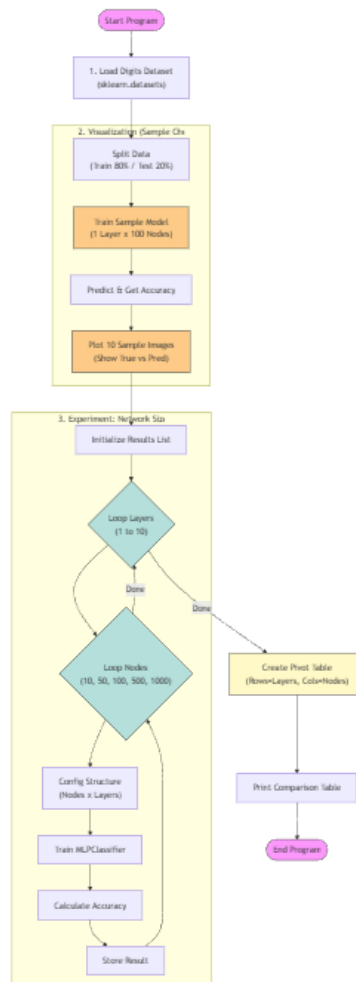
    img_path = os.path.join(class_path, img_name)
    try:
        with Image.open(img_path) as img:
            img = img.resize(image_size).convert('RGB')
            img_array = np.array(img).flatten() / 255.0

            images.append(img_array)
            labels.append(class_name)
            count += 1
    except Exception as e:
        pass
    print(f" -> Loaded {count} images from {class_name}")

return np.array(images), np.array(labels)

def main():
    print("="*50)
    print(" LAB 5: NN on Blood Cells Classification")
    print("="*50)

```



```

dataset_path = "../dataset/bloodcells"
if not os.path.exists(dataset_path):
    dataset_path = "dataset/bloodcells"

X, y_labels = load_data(dataset_path, image_size=(32,
32), max_samples_per_class=200)

if len(X) == 0:
    print("Error: No data loaded.")
    return

le = LabelEncoder()
y = le.fit_transform(y_labels)

X_train, X_test, y_train, y_test = train_test_split(X, y,
test_size=0.2, random_state=42)

print(f"\nFinal Split: {X_train.shape[0]} Train,
{X_test.shape[0]} Test samples")

print("\n" + "="*50)
print(" Experiment 1: Compare Network Sizes")
print("=" * 50)

layers_test = [1, 2, 5]
nodes_test = [10, 100, 500]

results_size = []

for l in layers_test:
    for n in nodes_test:
        hidden_layers = tuple([n] * l)
        print(f"Training: {l} Layers, {n} Nodes...")

```

```

        mlp =
MLPClassifier(hidden_layer_sizes=hidden_layers,
max_iter=200, random_state=42)
        mlp.fit(X_train, y_train)
        acc = mlp.score(X_test, y_test)

        results_size.append({'Layers': l, 'Nodes': n,
'Accuracy': acc})

df_size = pd.DataFrame(results_size)
pivot_size = df_size.pivot(index='Layers',
columns='Nodes', values='Accuracy')
print("\nNetwork Size Results:")
print(pivot_size)

print("\n" + "="*50)
print(" Experiment 2: Compare Learning Rates")
print("=" * 50)

learning_rates = [0.01, 0.001, 0.0001, 0.00001]

fixed_struct = (100, 100)

results_lr = []
best_model = None
best_acc = 0

for lr in learning_rates:
    print(f"Training LR: {lr}...")
    mlp = MLPClassifier(hidden_layer_sizes=fixed_struct,
learning_rate_init=lr, max_iter=300, random_state=42)
    mlp.fit(X_train, y_train)
    acc = mlp.score(X_test, y_test)

    results_lr.append({
        'Learning Rate': lr,

```

```

        'LR Sci': f"10^{int(np.log10(lr))}",
        'Accuracy': acc
    })

    if acc >= best_acc:
        best_acc = acc
        best_model = mlp

df_lr = pd.DataFrame(results_lr)[['LR Sci', 'Learning Rate',
'Accuracy']]
print("\nLearning Rate Results:")
print(df_lr)

print("\nDisplaying samples from Best Model...")

indices = np.random.choice(len(X_test), 10,
replace=False)
plt.figure(figsize=(15, 6))

for i, idx in enumerate(indices):
    img_show = X_test[idx].reshape(32, 32, 3)

    true_label = le.inverse_transform([y_test[idx]])[0]
    pred_label =
le.inverse_transform([best_model.predict([X_test[idx]])])[0]

    color = 'green' if true_label == pred_label else 'red'

    plt.subplot(2, 5, i+1)
    plt.imshow(img_show)
    plt.title(f"T: {true_label}\nP: {pred_label}",
color=color)

    plt.axis('off')
plt.tight_layout()
plt.show()

if __name__ == "__main__":

```

main()

Result:

```

Network Size Results:
Network Size Results:
Network Size Results:
Nodes      10      100      500
Layers
1      0.109375  0.753125  0.737500
2      0.112500  0.740625  0.715625
2      0.112500  0.740625  0.715625
5      0.540625  0.718750  0.712500

=====
Experiment 2: Compare Learning Rates
=====
Training LR: 0.01...
Training LR: 0.001...
Training LR: 0.01...
Training LR: 0.001...
Training LR: 0.001...
Training LR: 0.0001...
Training LR: 1e-05...

Learning Rate Results:
Learning Rate Results:
LR Sci  Learning Rate  Accuracy
0  10^-2      0.01000  0.656250
1  10^-3      0.00100  0.740625
2  10^-4      0.00010  0.743750
3  10^-5      0.00001  0.640625

Displaying samples from Best Model...

```

ให้ข้อคิดเห็น [สว11]: AI

1. ฟังก์ชันโหลดและเตรียมรูปภาพ (load_data)

ส่วนนี้ทำหน้าที่เป็น "คนเตรียมวัตถุดิบ" ก่อนส่งเข้าครัว (Neural Network):

- Scanning:** สแกนไฟล์เคอร์เพื่อหาชื่อคลาสอัตโนมัติ (เช่น Eosinophil, Lymphocyte)

•Image Processing:

- Resize:** ย่อรูปเหลือ 32x32 พิกเซล (กำหนดใน main) เพื่อให้คอมพิวเตอร์ประมวลผลไหว
- Flatten:** แปลงรูปภาพ 2 มิติ ให้เป็น เส้นตรง (Vector) เพราะ MLP รับข้อมูลแบบเส้นตรงเท่านั้น
- Normalization:** หาค่าเฉลี่ยด้วย 255.0 เพื่อปรับค่าให้อยู่ช่วง 0-1 (ช่วยให้ AI เรียนรู้ไวขึ้น)

2. การเตรียมข้อมูลหลัก (Main Data Setup)

- Label Encoding:** แปลงชื่อเซลล์เม็ดเลือด (Text) ให้เป็น ตัวเลข (0, 1, 2, ...) เพื่อให้คำนวณได้
- Train/Test Split:** แบ่งข้อมูลเป็น 2 กอง (80% ฝึกสอน, 20% ไว้สอบ)

3. การทดลองที่ 1: หาขนาดสมองที่เหมาะสม (Network Size Experiment)

- Grid Search:** วนูปทดสอบจับคู่โครงสร้างต่างๆ
- จำนวนชั้น (Layers): 1, 2, 5 ชั้น
- จำนวนเซลล์สมอง (Nodes): 10, 100, 500 ตัว
- Pivot Table:** สรุปผลออกมาเป็นตารางเพื่อดูว่าโครงสร้างไหนให้ความแม่นยำ (Accuracy) สูงสุด

4. การทดลองที่ 2: หาอัตราการเรียนรู้ (Learning Rate Experiment)

- ใช้โครงสร้างคงที่ (2 ชั้น, 100 โหนด) แล้วเปลี่ยนความเร็วในการเรียนรู้ (0.01 ถึง 0.00001)
- Best Model Tracking:** ไล่คดจะคอยจำว่าโมเดลตัวไหนเก่งที่สุด (best_model) เพื่อเอาไว้ใช้โชว์ผลงานในตอนท้าย

LEB 6: NN with Smoothed COVID-19 Data.

LINK: <https://www.kaggle.com/datasets/hosammhmdali/covid-19-dataset>

Objective:

- Apply NN to Smoothed COVID-19 Data (.CSV) (THA).

Contents:

- Load the smoothed COVID-19 dataset from a CSV file (provided link).
- Preprocess the data and split it into training and testing sets.
- Construct and train NN models with 10 hidden layers (1 layers: 100 nodes).
- Evaluate the performance of each NN model using the accuracy metric..

Output:

- Accuracy score of each NN for comparison across different layers and nodes.
- Time-series plots comparing: Actual, Smoothed Trend, and NN Forecast for 3-month and 6-month forecasting horizons, similar to the provided example figure.

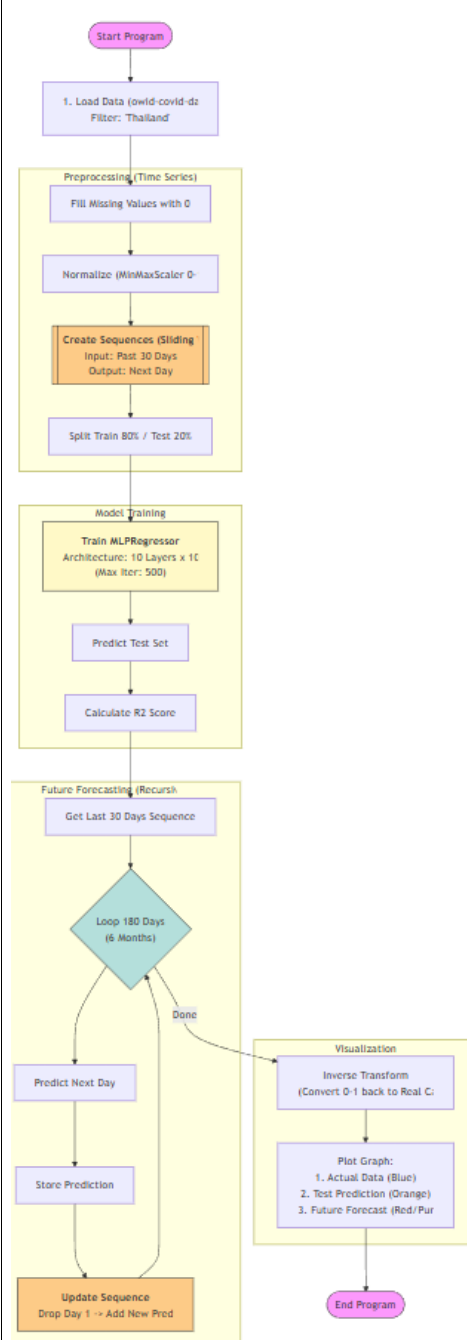
Code or Algorithms:	Flowchart:
<pre> import pandas as pd import numpy as np import matplotlib.pyplot as plt from sklearn.neural_network import MLPRegressor from sklearn.preprocessing import MinMaxScaler from sklearn.metrics import r2_score import os def create_sequences(data, seq_length): xs = [] ys = [] for i in range(len(data)-seq_length-1): x = data[i:(i+seq_length)] y = data[i+seq_length] xs.append(x) ys.append(y) return np.array(xs), np.array(ys) def main(): print("="*50) print(" LAB 6: NN on Smoothed COVID-19 Data (Forecasting)") print("="*50) # 1. Load Data dataset_path = "../dataset/covid/owid-covid- data.csv" if not os.path.exists(dataset_path): dataset_path = "dataset/covid/owid-covid- data.csv" print(f"Loading dataset from: {dataset_path}") try: df = pd.read_csv(dataset_path) except FileNotFoundError: print("Error: Dataset not found.") </pre>	

```

return
# 2. Filter Data (Thailand, Smoothed Cases)
country = 'Thailand'
target_col = 'new_cases_smoothed'
print(f"Filtering data for: {country}")
df_thai = df[df['location'] == country].copy()
df_thai['date'] = pd.to_datetime(df_thai['date'])
df_thai = df_thai.sort_values('date')
# Handle Missing Values
df_thai[target_col] = df_thai[target_col].fillna(0)
data = df_thai[target_col].values.reshape(-1, 1)
dates = df_thai['date'].values
print(f"Total Records: {len(data)}")
# 3. Preprocessing
scaler = MinMaxScaler()
data_normalized = scaler.fit_transform(data)
# Create Sequences
seq_length = 30 # Look back 30 days to predict
next day
X, y = create_sequences(data_normalized,
seq_length)

# Split Train/Test (80/20)
train_size = int(len(X) * 0.8)
X_train, X_test = X[:train_size], X[train_size:]
y_train, y_test = y[:train_size], y[train_size:]
# Flatten input for MLP (samples, features) ->
(samples, seq_length)
X_train = X_train.reshape(X_train.shape[0], -1)
X_test = X_test.reshape(X_test.shape[0], -1)
print(f"Training Samples: {X_train.shape[0]}")
print(f"Testing Samples: {X_test.shape[0]}")
# 4. Train NN Model
# 10 Hidden Layers, 100 Nodes each
hidden_layers = tuple([100] * 10)

```



```

print(f"Training MLPRegressor with Architecture:
{hidden_layers}")

mlp =
MLPRegressor(hidden_layer_sizes=hidden_layers,
              activation='relu',
              solver='adam',
              max_iter=500,
              random_state=42)

mlp.fit(X_train, y_train.ravel())
# 5. Evaluate
y_pred_test = mlp.predict(X_test)
y_pred_test_inv =
scaler.inverse_transform(y_pred_test.reshape(-1, 1))
y_test_inv =
scaler.inverse_transform(y_test.reshape(-1, 1))
score = r2_score(y_test_inv, y_pred_test_inv)
print(f"Model R2 Score (Accuracy): {score:.4f}")

# 6. Forecast Future
# We need the last sequence from the entire data
to start forecasting future
last_sequence = data_normalized[-
seq_length:].reshape(1, -1)
future_days_3m = 90
future_days_6m = 180
forecast_3m = []
curr_seq = last_sequence.copy()
print(f"Forecasting next {future_days_6m} days...")
for i in range(future_days_6m):
    next_pred = mlp.predict(curr_seq)[0]
    if i < future_days_3m:
        forecast_3m.append(next_pred)
# Update sequence: remove first element, add
new prediction

```

```

curr_seq = np.append(curr_seq[:, 1:],
[[next_pred]], axis=1)
forecast_6m = forecast_3m + [curr_seq[0, -1]] #
Continuation (simplified logic for list storage)
# Actually, let's re-run loop or just store all 180
# Re-doing clean forecast list
forecast_full = []
curr_seq = last_sequence.copy()
for i in range(future_days_6m):
    next_pred = mlp.predict(curr_seq)[0]
    forecast_full.append(next_pred)
    curr_seq = np.append(curr_seq[:, 1:],
[[next_pred]], axis=1)
forecast_full_inv =
scaler.inverse_transform(np.array(forecast_full).reshape(-
1, 1))
# Generate Dates for Forecast
last_date = dates[-1]
future_dates = pd.date_range(start=last_date +
pd.Timedelta(days=1), periods=future_days_6m)
# 7. Plot Results
plt.figure(figsize=(12, 6))

# Plot Actual Data (Historical)
plt.plot(dates, data, label='Actual / Smoothed
Trend', color='blue', alpha=0.6)
# Plot Test Predictions (to see model fit)
# Align dates for test predictions
test_dates = dates[train_size+seq_length+1 :
train_size+seq_length+1+len(y_test)]
# Note: alignment can be tricky with sequences.
# Index of y_test[0] corresponds to original data
index: train_size + seq_length
test_date_indices = range(train_size + seq_length,
train_size + seq_length + len(y_test))
test_dates_plot = dates[test_date_indices]

```

```
plt.plot(test_dates_plot, y_pred_test_inv,
label='Model Test Prediction', color='orange',
linestyle='--')

# Plot 3-Month Forecast
plt.plot(future_dates[:90], forecast_full_inv[:90],
label='3-Month Forecast', color='red', linewidth=2)

# Plot 6-Month Forecast (Extension)
plt.plot(future_dates[90:], forecast_full_inv[90:],
label='6-Month Forecast', color='purple', linestyle=':',
linewidth=2)

plt.title(f'COVID-19 Forecasting (Thailand) - R2 Score:
{score:.4f}')

plt.xlabel('Date')
plt.ylabel('New Cases Smoothed')
plt.legend()
plt.grid(True)
plt.tight_layout()
plt.show()

if __name__ == "__main__":
    main()
```

ให้จัดให้ [สว12]: AI

1. การเตรียมฟังก์ชันช่วย (create_sequences)

ส่วนนี้สำคัญที่สุดสำหรับโจทย์ Time Series (อนุกรมเวลา)

• **หน้าที่:** แปลงข้อมูลตัวเลขเรียงกันยาวๆ ให้เป็นรูปแบบ **Input (อดีต) -> Output (อนาคต)**

• **วิธีการ (Sliding Window):** ใช้หน้าต่างขนาด 30 วัน (seq_length) เลื่อนไปทีละวัน เพื่อสร้างชุดข้อมูล เช่น:

- Input: ข้อมูลวันที่ 1-30 -> Target: วันที่ 31
- Input: ข้อมูลวันที่ 2-31 -> Target: วันที่ 32

2. การโหลดและกรองข้อมูล (Load & Filter Data)

• โหลดไฟล์ CSV owid-covid-data.csv

• **Filter:** เลือกเฉพาะประเทศไทย (Thailand) และเลือกคอลัมน์ new_cases_smoothed (ผู้ติดเชื้อรายใหม่แบบเฉลี่ย) ซึ่งจะช่วยลดความผันผวนรายวัน ทำให้โมเดลเรียนรู้แนวโน้มได้ดีกว่า

• **Cleaning:** เติมค่าว่าง (NaN) ด้วย 0 เพื่อป้องกัน Error

3. การเตรียมข้อมูลก่อนเข้าโมเดล (Preprocessing)

• **Normalization:** ใช้ MinMaxScaler ปรับข้อมูลทั้งหมดให้อยู่ในช่วง 0 ถึง 1 เพื่อให้ Neural Network คำนวณได้เร็วและแม่นยำขึ้น

• **Sequence Creation:** เรียงฟังก์ชันจากข้อ 1 มาแบ่งข้อมูลเป็นชุดๆ (ดูย้อนหลัง 30 วัน)

• **Split Data:** แบ่งข้อมูลเป็น Train (80%) และ Test (20%) เพื่อใช้สอนและวัดผลโมเดล

4. การสร้างและเทรนโมเดล (Model Training)

• **Deep Neural Network:** สร้างโมเดล MLPRegressor ที่มีควมลึกมาก (Deep Learning)

• **Structure:** ใช้ Hidden Layers ถึง 10 ชั้น ชั้นละ 100 โหนด (tuple([100] * 10)) เพื่อให้โมเดลมีความซับซ้อนพอที่จะจับ Pattern ของการระบาดได้

• **Training:** ตั้ง fit เพื่อให้โมเดลเรียนรู้จากข้อมูล Train

5. การวัดผล (Evaluation)

• นำโมเดลไปทำนายข้อมูลชุด Test

• **Inverse Transform:** แปลงค่าผลลัพธ์จาก 0-1 กลับมาเป็นจำนวนคนติดเชื้อจริง

• **R2 Score:** คำนวณค่าความแม่นยำ (ยิ่งเข้าใกล้ 1.0 ยิ่งดี) เพื่อดูว่าโมเดลทำนายแนวโน้มได้ถูกต้องแค่ไหน

6. การพยากรณ์อนาคต (Future Forecasting)

ส่วนนี้ใช้เทคนิค **Recursive Forecasting** (ทำนายแบบวนซ้ำ):

• เริ่มต้นด้วยข้อมูล 30 วันสุดท้ายที่มีอยู่จริง

• **Loop 180 รอบ (6 เดือน):**

- 1. ให้โมเดลทำนายวันถัดไป
- 2. เก็บผลลัพธ์ไว้

3. **Update Input:** คัดข้อมูลวันแรกทิ้ง แล้วเอาผลที่เพิ่งทำนายได้ใส่ต่อท้าย เพื่อใช้ทำนายวันถัดไป

Result:

